

Credit Risk Prediction Model

Final Task - ID/X Partners x Rakamin Academy (Data Scientist Virtual Internship) Allan
Glory Krisrodemar | NRP 3124510118

Latar Belakang & Tujuan

Perusahaan lending ingin menilai risiko kredit calon peminjam dengan lebih objektif. Project ini membangun model machine learning untuk memprediksi apakah suatu pinjaman berpotensi gagal bayar (bad loan) atau tidak (good loan), berdasarkan data historis pinjaman LendingClub periode 2007-2014.

Gambaran Dataset

466.285 data pinjaman, 74 kolom/atribut.

Komposisi target: 88,1% good loan vs 11,9% bad loan (imbalanced).

Metodologi

1. Data Understanding
2. Exploratory Data Analysis
3. Data Preparation
4. Data Modelling
5. Evaluation & Rekomendasi



Definisi Target

Good loan: Fully Paid, Current, - Suku bunga (int_rate) & grade LC berkorelasi
paling kuat dengan risiko gagal bayar

Bad loan: Charged Off, Default, Late
(16-30 & 31-120 hari), In Grace Period,
Does not meet credit policy - Charged Off

Faktor Paling Berpengaruh

- Debt-to-Income (dti) tinggi -> risiko naik
- Grade E/F/G jauh lebih berisiko dibanding A/B
- Home ownership RENT sedikit lebih berisiko



Perbandingan algoritma machine learning yang digunakan


Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Logistic Regression	0.610	0.180	0.650	0.290	0.679
Random Forest	0.630	0.190	0.640	0.290	0.685
XGBoost *	0.630	0.190	0.660	0.300	0.695

ROC Curve Perbandingan Model

Legend:

- Logistic Regression (AUC=0.679)
- Random Forest (AUC=0.683)
- XGBoost (AUC=0.691)

The graph shows the True Positive Rate (Y-axis) versus the False Positive Rate (X-axis) for three models. The XGBoost model (red line) has the highest AUC value (0.691), followed by Random Forest (orange line, AUC=0.683) and Logistic Regression (blue line, AUC=0.679). All three models perform significantly better than a random classifier (dashed diagonal line).



1. Gunakan model XGBoost sebagai scoring tool tambahan dalam proses persetujuan pinjaman, khususnya untuk mendeteksi pengajuan dengan indikasi risiko tinggi lebih awal.
2. Perhatikan khusus pengajuan dengan suku bunga tinggi, grade C ke bawah, dan rasio dti tinggi -- kombinasi ini paling banyak berasosiasi dengan bad loan.
3. Skor model sebaiknya jadi salah satu pertimbangan (bukan satu-satunya faktor), dikombinasikan dengan kebijakan kredit dan judgment tim analis kredit.
4. Untuk pengembangan lanjutan: pertimbangkan threshold tuning sesuai selera risiko bisnis, serta eksplorasi fitur tambahan untuk meningkatkan recall pada bad loan.

Model dilatih hanya menggunakan fitur yang tersedia saat pinjaman diajukan (menghindari data leakage dari fitur hasil pembayaran), sehingga performa (ROC-AUC sekitar 0,68-0,69) mencerminkan kemampuan prediksi yang realistis dari informasi yang benar-benar tersedia di titik keputusan. Seluruh proses dapat direplikasi ulang melalui notebook dan kode terlampir.